بسم اللّه الرحمن الرحیم

پروژه پایانی پردازش زبان طبیعی

غزاله محمودی

۵ تیر ۱۴۰۰

فهرست مطالب

فهرست تصاویر

۱ word2vec

در این بخش قصد داریم با استفاده از ماژول gensim بردار word2vec را برای هر کلمه حساب کنیم.
دست آوردن word2vec به کمک Gensim تعدادی پارامتر قابل تنظیم دارد که در ادامه به بررسی آن ها می پردازم.

- Size

این پارامتر تعیین کننده سایز vector برای نمایش هر word یا token است. هر چه دیتاست محدود تر و کوچک‌تر باشد این عدد نیز کوچک‌تر در نظر گرفته می شود و هر چه دیتاست بزرگ‌تر باشد(کلمات unique بیشتری داشته باشد) باید اندازه vector بزرگ‌تر در نظر گرفته شود. تجربه نشان داده اندازه بین ۱۰۰ تا ۱۵۰ برای دیتاست‌های بزرگ مقدار مناسبی است.

- Windows

این پارامتر تعیین کننده بیشترین فاصله مابین کلمه اصلی و همسایه‌های آن می‌باشد.از لحاظ تئوری هر چه این سایز کوچکتر باشد کلماتی که بیشترین ارتباط معنایی را به یکدیگر دارند به عنوان خروجی برمی گرداند. اگر تعداد داده به اندازه کافی بزرگ باشد سایز پنجره اهمیت زیادی ندارد اما باید این نکته را در نظر گرفت که این سایز نباید خیلی بزرگ یا بیش از حد کوچک باشد. اگر درباره انتخاب آن اطمینان نداریم بهتر است از مقدار پیش فرض استفاده کنیم.

- Min count

این پارامتر حداقل تکرار کلمه در دیتاست را نشان می‌دهد که در صورتی که کلمه ای به این تعداد تکرار شود در word embedding مورد توجه قرار می‌گیرد و در غیر این صورت کنار گذاشته می‌شود. تعیین این عدد در دیتاست‌های بزرگ برای کنار گذاشتن کلمات کم اهمیت که غالبا کم تکرار می‌شوند مناسب است. همچنین در مصرف بهینه مموری و حافظه هم تاثیر دارد.

۱.۱ بررسی bias

در این بخش احتمال وجود bias در دیتاست مورد بررسی قرار گرفت. برای این منظور مشابهت‌های مقابل مورد بررسی قرار گرفت.

woman as doctor similar as man as ?

که خروجی به صورت شکل۱ شد.

	word	score
0	psychiatrist	0.539148
1	therapist	0.494201
2	sent	0.490427
3	appointment	0.451637
4	symptom	0.440813
5	medication	0.419075
6	nearly	0.415111
7	ward	0.413921
8	adhd	0.403657
9	med	0.399072

شکل ۱: woman as doctor similar as man as ?

در ادامه برای پیدا کردن bias احتمالی بین زن و مرد در این دیتاست به ازای ورودی زیر اجرا را تکرار کردیم. خروجی به صورت شکل۲ شد.

man as doctor similar to woman as ?

	word	score
0	mum	0.499389
1	sister	0.489097
2	dad	0.462778
3	upset	0.453062
4	therapist	0.451369
5	mad	0.449687
6	phone	0.448865
7	anyway	0.448734
8	psychiatrist	0.442708
9	appointment	0.441602

شکل ۲: man as doctor similar to woman as ?

همان‌طور که در گزارشات مطرح شده به وضوح مشخص است این دیتا برای جنسیت خانم‌ها و آقایان bias دارد. در مورد اول اگر شغل زن را دکتر فرض کنیم، مدل برای مرد شغل روان‌پزشک که شاخه‌ای از پزشکی است را انتخاب می‌کند. اما در آزمایش دوم هنگامی که شغل مرد را دکتر در نظر می‌گیریم، برای شغل زن mum را انتخاب می‌کند. گرچه مادری از جایگاه بالایی برخوردار است اما در اینجا نشان‌دهنده bias بر روی جنسیت می‌باشد.

۲.۱ بررسی بردارهای کلمات مشابه در کلاس‌های مختلف

در این بخش بردارهای کلمات مشترک در دو دسته depresion و happiness را مورد بررسی قرار دادیم. در این آزمایش برای بردارها cosine similarity را محاسبه کردیم. اگر دو بردار کاملا یکسان باشند مقدار cosine similarity برابر با ۱ یا نزدیک به ۱ می‌شود و در غیر این صورت مقادیر کوچک تر از ۱ می‌باشد. نتیجه محاسبه cosine similarity برای چند کلمه مشترک بین دسته‌ها به صورت شکل۳ است.

	word	cosine similarity value
0	working	0.195335
1	time	-0.091545
2	able	0.124327
3	good	-0.018955
4	depression	-0.106198
5	life	-0.169888
6	believe	0.118834
7	anxiety	-0.049866
8	human	0.090089
9	beautiful	-0.075464

شکل ۳: cosine similarity common words

همان‌طور که مشخص است اکثر کلمات یکسان در دسته‌های مختلف بردارهای متفاوتی دارد. دلیل این امر این است که با توجه به context که کلمه در هر کلاس آمده، بردار مورد نظر به دست آمده است. با توجه به اینکه کلمات در متن‌های متفاوتی هستند پس بردارهای متفاوتی برای آن‌ها وجود دارد.

در ادامه بررسی کلمات مشترک کلاس‌های مختلف 10 most similarr words را برای کلمه life بررسی کردیم و بردار ۶۴ بعدی را در نمودار ۲ بعدی نمایش دادیم. ۱۰ کلمه برتر کلاس depresion در شکل۴ و ۱۰ کلمه برتر کلاس happiness در شکل۵ می‌باشد.

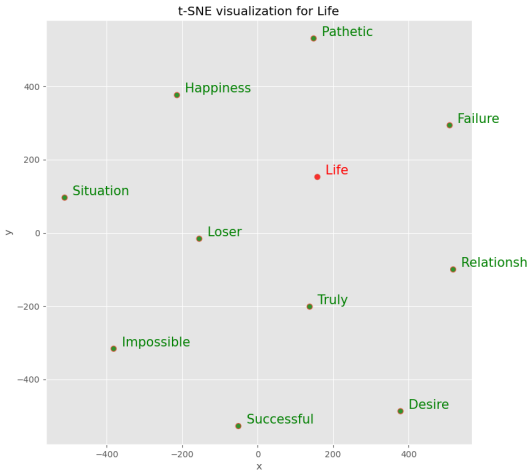

شکل ۴: بردار ۱۰ کلمات مشابه life

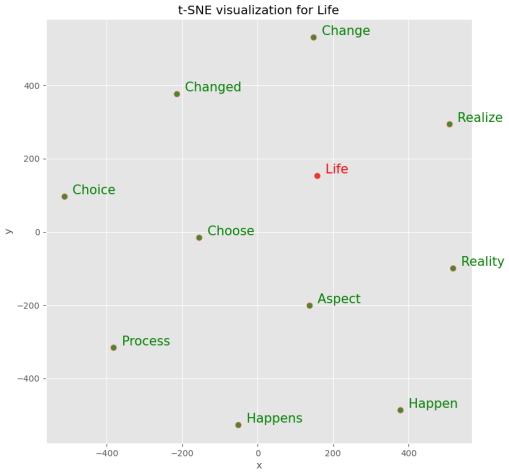

شکل ۵: بردار ۱۰ کلمات مشابه life

۲ tokenization

در این قسمت ابتدا پنج vocab size برای tokenize کردن داده انتخاب می‌کنیم. دیتا را به پنج بخش تقسیم کرده و در هر مرحله آزمایش، یک بخش به عنوان داده ارزیابی و چهار بخش باقی مانده را به عنوان داده آموزشی در نظر می‌گیریم. به ازای هر vocab size در این بخش tokenize در مرحله word اجرا می‌شود و id توکن unk عدد سه در نظر گرفته شده است. پنج بار آزمایش انجام می‌دهیم. مدل رت روی داده‌های آموزشی train کرده ودر انتها تعداد توکن‌های unk را به ازای vocab size های مختلف بر روی داده ارزیابی بررسی می‌کنیم. نتایج به دست آمده در شکل۶ قابل مشاهده است.

	token count	1	2	3	4	5	average unk token percent
0	60	42.39	42.50	42.58	42.49	42.31	42.454
1	500	25.67	25.47	25.49	25.16	25.40	25.438
2	2000	11.91	11.88	11.76	11.65	11.69	11.778
3	5000	5.71	5.60	5.57	5.50	5.62	5.600
4	10067	2.54	2.47	2.46	2.36	2.36	2.438

شکل ۶: tokenization result

همچنین نتایج به صورت متن در reports/tokenization.txt و log برنامه در logs/tokenization.log موجود است. برای اجرا آزمایش‌ها و ذخیره مدل نهایی در پوشه مورد نظر کافیست

python tokenization/tokenization.py

اجرا شود.

همان‌طور که انتظار می‌رفت با افزایش تعداد vocab size تعداد توکن‌های unk به مقدار قابل توجهی کاهش می‌یابد.

parsing ۳

در این قسمت به کمک کد تمرین ۳ مدل dependency parser را بر روی زبان انگلیسی آموزش داده و تعدادی جمله از دیتاست را انتخاب کرده و parse متناظر با آن‌ها را به صورت دستی نوشته و به عنوان فایل تست، قرار می‌دهیم. فایل تست تولید شده در src/parsing/data/project_data_test.conll قابل مشاهده است (شکل۷). اجرا برنامه به کمک دستور python parsing/run.py میسر می‌باشد.

```
1   1   how  _   ADV  WRB  _   4   aux    _   _
2   2   do   _   AUX  VBP  _   4   nsubj  _   _
3   3   i    _   PRON PRP  _   4   nsubj  _   _
4   4   help _   VERB VB   _   0   root   _   _
5   5   my   _   DET  VB   _   6   PRP    _   _
6   6   mum  _   NOUN NN   _   4   dobj   _   _
7   7   ?    _   PUNCT .    _   4   punct  _   _
8
```

شکل ۷: correct dependency parser

به عنوان مثال مدل برای جمله موجود در شکل۸ dependency parser را به طور کامل درست تشخیص داده است.

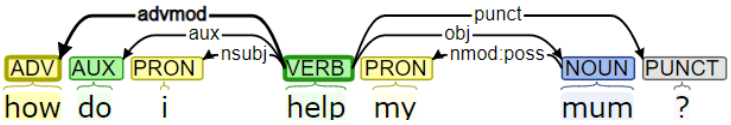

شکل ۸: correct dependency parser

نکته‌ای که در ساخت فایل conll بسیار مهم است و باید بدان توجه شود این است که بین موارد نوشته شده باید یک tab فاصله باشد و در صورت عدم رعایت این فاصله جملات توسط parser به صورت اشتباه خوانده می‌شوند. پس از اجرا تست test UAS: 80.00 به دست آمد. مدل در جملات پیچیده و گاها با دو فعل (و یا جملات ساده‌ای که در داده‌های آموزشی نباشند) در تشخیص root دچار مشکل شده و اشتباهات به صورت سلسله‌وار به وجود می‌آید.
به عنوان مثال در جمله .not sure what to do واژه not را به عنوان root در نظر گرفته در صورتی که پارس صحیح جمله به صورت شکل۹ است.

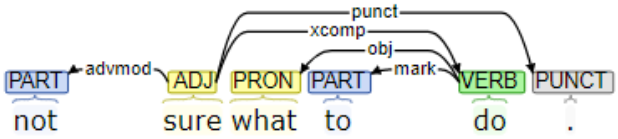

شکل ۹: correct dependency parser

۴ language model

در این بخش برای آموزش language model ابتدا داده تمیز را به صورت مناسب آماده می‌کنیم. سپس به ازای هر کدام از دسته‌های depresion و happiness داده را به شبکه داده تا مدل زبانی آموزش ببیند. در معماری تعریف شده ایتدا یک لایه embedding قرار داده شده و در ادامه لایه LSTM با 100 hidden state قرار دارد. لایه دیگری bidirectional LSTM و در ادامه یک لایه dense قرار دارد. لایه انتهایی یک لایه dense با تابع فعال‌سازی softmax می‌باشد که به تعداد همه کلمات موجود نورون دارد. در این لایه به ازای ورودی شبکه مشخص می‌شود چه کلمه باید بعد از عبارت ورودی شبکه بیاید. مدل تعریف شده به صورت شکل۱۰ می‌باشد. دقت و loss برای کلاس‌های مختلف به صورت شکل۱۱ و شکل۱۲ است.

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
embedding (Embedding)        (None, 10, 50)            499250
_________________________________________________________________
lstm (LSTM)                  (None, 10, 100)           60400
_________________________________________________________________
bidirectional (Bidirectional (None, 200)               160800
_________________________________________________________________
dense (Dense)                (None, 100)               20100
_________________________________________________________________
dense_1 (Dense)              (None, 9985)              1008485
=================================================================
Total params: 1,749,035
Trainable params: 1,749,035
Non-trainable params: 0
```

شکل ۱۰: شبکه language model

```
Epoch 92/100
1221/1221 [==============================] - 48s 40ms/step - loss: 2.1851 - accuracy: 0.5296
Epoch 93/100
1221/1221 [==============================] - 51s 41ms/step - loss: 2.1756 - accuracy: 0.5306
Epoch 94/100
1221/1221 [==============================] - 55s 45ms/step - loss: 2.1517 - accuracy: 0.5362
Epoch 95/100
1221/1221 [==============================] - 49s 40ms/step - loss: 2.1539 - accuracy: 0.5357
Epoch 96/100
1221/1221 [==============================] - 49s 40ms/step - loss: 2.1635 - accuracy: 0.5344
Epoch 97/100
1221/1221 [==============================] - 53s 43ms/step - loss: 2.1472 - accuracy: 0.5371
Epoch 98/100
1221/1221 [==============================] - 54s 44ms/step - loss: 2.1362 - accuracy: 0.5380
Epoch 99/100
1221/1221 [==============================] - 48s 40ms/step - loss: 2.1314 - accuracy: 0.5390
Epoch 100/100
1221/1221 [==============================] - 49s 40ms/step - loss: 2.1096 - accuracy: 0.5418
```

شکل ۱۱: LSTM accuracy and Loss language model on class depression

با توجه به حذف stopwords و punctuation از جمله و کم‌بودن دیتا برای آموزش یک مدل زبانی مناسب، مشکلاتی در نحوه جمله بندی و قواعد گرامری جمله ساخته شده توسط مدل وجود دارد. عدم وجود I ، am ، are و حروف اضافه‌ای همچون thst is، در زمان تمیز کردن دیتا باعث شده چنین جملاتی

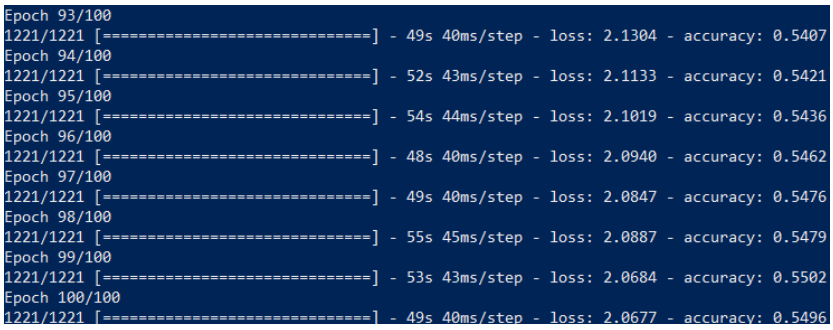

شکل ۱۲: LSTM accuracy and Loss language model on class happiness

به وجود بیایند. از طرفی شبکه آموزش دیده pretrain نبوده و برای اولین بار آموزش می بیند و برای آموزش بهتر نیاز به دیتا بسیار بیشتری از حجم دیتا فعلی دارد.

- happiness

take break outside lunch feel like everyone office hate think boring since forced office romantic vacation friend friend whole money laying

- depression

kill prayed god make accident happen year old relationship family know remember im told reminds friend something really eventually wa using

- happiness

i feel so like losing grow shell remember hate suck suck fucked cant

- depression

i feel so like edgy movie mind hold supportive defense trash sea man

برای اجرا این بخش کافیست python language_model.py را اجرا کنید. به ازای هر کدام از کلاس‌های depresion و happiness مدل را finetune کرده و وزن‌های حاصله به صورت اتوماتیک در models/language_model/depression_language_model.h5 و models/language_model/happiness_language_model.h5 ذخیره می‌شوند. همچنین log در حین اجرا در logs/language_model.log قابل مشاهده هست.

finu tuning ۵

language model ۱.۵

در این بخش با توجه به مطالعات انجام شده بر روی مدل‌های GPT2 در language model و کیفیت خروجی مدل برای این تسک، از distilgpt2 به عنوان مدل pretrain استفاده کرده و مدل را بر دیتاست موجود finetune کردم.

برای اجرا این بخش کافیست python fine_tuning.py GPT2 را اجرا کنید. به ازای هر کدام از کلاس‌های depresion و happiness مدل را finetune کرده و وزن‌های حاصله به صورت اتوماتیک در models/depressionGPT2_lm و mosels/happinessGPT2_lm ذخیره می‌شوند. همچنین log در حین اجرا در logs/fine_tuning_GPT2.log قابل مشاهده هست. نمودار تغییرات loss مدل در زمان finetune برای کلاس depression به صورت شکل۱۳ و برای کلاس happiness به صورت شکل۱۴ می‌باشد.

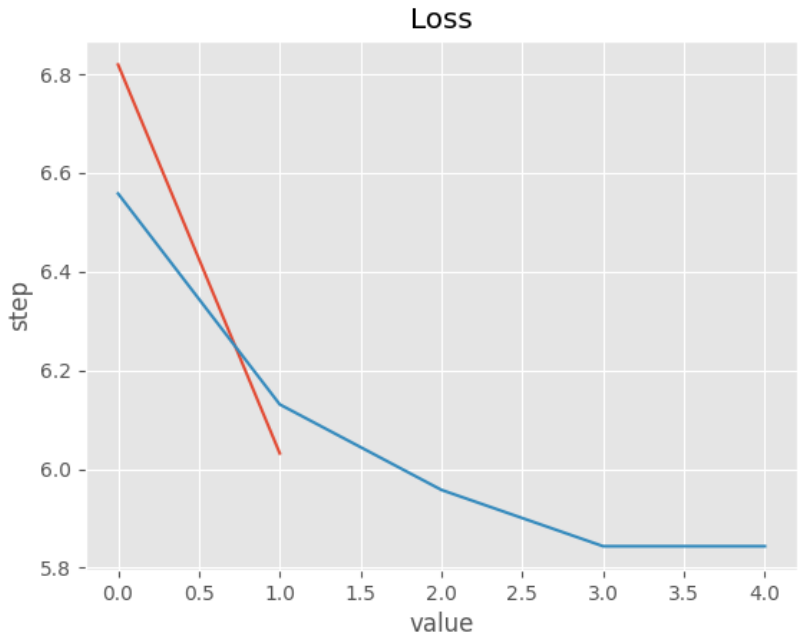

شکل ۱۳: distilgpt2 Loss language model on class depression

شکل ۱۴: distilgpt2 Loss language model on class happiness

جملات تولید شده با مدل از قبل آموزش دیده distilgpt2 بسیار با کیفیت‌ترو معنی‌دارتر از جملات تولید شده در قسمت قبل می‌باشد. به ازای هر کدام از کلاس‌ها دو جمله تولید شده که به صورت زیر می‌باشد. نوشته به رنگ آبی توسط مدل تولید شده است.

- happiness

Hi, we have created a success forum for people interested interested know help support success success want like like get rich life know want give give want give back give want give know want give take

- depression

Hi, we have created a success forum for people interested interested know going want succeed going want fail people want know go past time never successful people want know go past time know succeeding people want know go past time life lived time lived past moment

- happiness

I'm so depressed. I have nothing to livepeople like that time ago and everything felt normal today really worked like ever since even though everyone else would take back everything back everything right moment every morning would feel like day today felt normal today feel

- depression

I'm so depressed. I have nothing to livelike two people say like crazy thing say everything said nothing said anything anything said anything actually meant anything else meant anything meant nothing meant anything anything meant anything else never truly meant anything know want need understand needed know

نکته قابل تامل این است که حجم دیتا depression نسبت به happiness اندکی بیشتر است و به نظر می‌رسد این موضوع نحوه آموزش تاثیر گذاشته است. همچنین عملکرد مدل GPT برای ساخت جملات طولانی بهتر از LSTM می‌باشد.

۲.۵ classification

در بخش دوم مدل bert-base-uncased از قبل آموزش دیده را برای classification داده‌ها بر روی داده‌های موجود finetune می‌کنیم. برای اجرا این بخش کافیست python fine_tuning.py Bert را اجرا کرد. وزن‌های مدل finetune شده در models/bert_classification_lm ذخیره می‌شوند. همچنین log در حین اجرا در logs/fine_tuning_Bert.log می‌باشد. نمودار تغییرات loss در شکل۱۵ قابل مشاهده است.

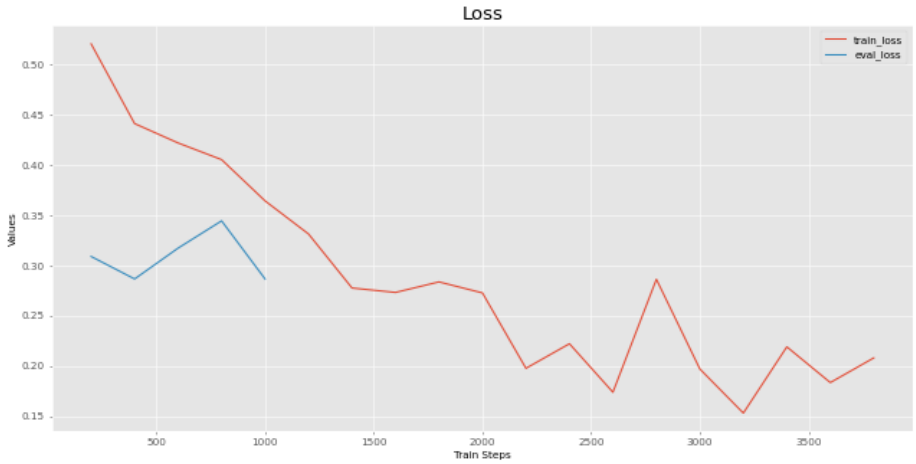

شکل ۱۵: bert-base-uncased Loss classification

نمونه خروجی classification به ازای ۴ جمله ورودی در logs/fine_tuning_Bert.log موجود می‌باشد.

۶ نحوه اجرا پروژه

برای آماده‌سازی کامپیوتر شخصی برای اجرا پروژه ابتدا لازم است با اجرا دستور زیر envirment مورد نیاز را ساخته و آن را فعال کنیم.

```
conda env create -f local_env.yml
conda activate project_env
```

در ادامه برای اجرا کلیه مراحل فاز پایانی پروژه کافیست کامند زیر را اجرا کنید. اجرا در سیستم عامل لینوکس با درستور

```
sh run.sh
```

و بر روی ویندوز با دستور

```
(windows) run.bat
```

می‌باشد. راهنمای اجرا هر بخش از پروژه در قسمت مربوط به آن موجود می‌باشد.

۷ منابع

https://www.kaggle.com/pierremegret/gensim-word2vec-tutorial
https://radimrehurek.com/gensim/models/word2vec.html
https://www.philschmid.de/
fine-tune-a-non-english-gpt-2-model-with-huggingface
https://machinelearningmastery.com/
how-to-develop-a-word-level-neural-language-model-in-keras/
https://gmihaila.github.io/tutorial_notebooks/pretrain_
transformers_pytorch/
https://stackoverflow.com/questions/52277384/
calculation-of-cosine-similarity-of-a-single-word-in-2-different-word2vec-models
http://stanza.run/