بسم اللّه الرحمن الرحیم

# پروژه پایانی پردازش زبان طبیعی

غزاله محمودی

۵ تیر ۱۴۰۰

# فهرست مطالب

# فهرست تصاویر

فهرست جداول

## word2vec ۱

در این بخش قصد داریم با استفاده از ماژول gensim بردار word 2 vec را برای هر کلمه حساب کنیم. ابتدا لازم است دیتاست را برای استفاده آماده کنیم. به کمک pandas و نظرات موجود را استخراج می کنیم. در نهایت DataFrame به صورت زیر حاصل می شود.

در ادامه به ازای تمام نظرات(جملات) موجود در دیتاست کلمات موجود در آن ها را استخراج می کنیم. این کار با استفاده از tokenizer ماژول HAZM انجام می دهیم.

برای به دست آوردن word۲vev به کمک Gensim تعدادی پارامتر قابل تنظیم دارد که در ادامه به بررسی آن ها می پردازم.

- Size

  این پارامتر تعیین کننده سایز vector برای نمایش هر word یا token است. هر چه دیتاست محدود تر و کوچکتر باشد این عدد نیز کوچک تر در نظر گرفته می شود و هر چه دیتاست بزرگتر باشد(کلمات unique بیشتری داشته باشد) باید اندازه vector بزرگتر در نظر گرفته شود. تجربه نشان داده اندازه بین ۱۰۰ تا ۱۵۰ برای دیتاست های بزرگ مقدار مناسبی است.

- Windows

  این پارامتر تعیین کننده بیشترین فاصله مابین کلمه اصلی و همسایه های آن می باشد.از لحاظ تئوری هر چه این سایز کوچکتر باشد کلماتی که بیشتر ارتباط را به یکدیگر دارند به عنوان خروجی برمی گرداند. اگر تعداد داده به اندازه کافی بزرگ باشد سایز پنجره اهمیت زیادی ندارد اما باید این نکته را در نظر گرفت که این سایز نباید خیلی بزرگ یا بیش از حد کوچک باشد. اگر درباره انتخاب آن اطمینان نداریم بهتر است از مقدار پیش فرض استفاده کنیم.

- Min count

  این پارامتر حداقل تکرار کلمه در دیتاست را نشان می دهد که در صورتی که کلمه ای به این تعداد تکرار شود در word embedding مورد توجه قرار می گیرد و در غیر این صورت کنار گذاشته می شود. تعیین این عدد در دیتاست های بزرگ برای کنار گذاشتن کلمات کم اهمیت که غالبا کم تکرار می شوند مناسب است. همچنین در مصرف بهینه ممووری و حافظه هم تاثیر دارد.

- Workers

  این پارامتر تعداد thread هایی که در عملیات اجرا مورد استفاده قرار می گیرد را مشخص می کند. برای عملیات بهینه سازی و افزایش سرعت اجرا در سیستم هایی که قابلیت پردازش موازی دارند.

- Iter

  تعداد epoch یا دفعاتی که الگوریتم اجرا می شود و مدل آموزش می بیند.

- seed

  برای مقدار دهی رندوم اولیه استفاده می شود.

## ۲ tokenization

در این قسمت ابتدا پنج vocab size برای tokenize کردن داده انتخاب می‌کنیم. دیتا را به پنج بخش تقسیم کرده و در هر مرحله آزمایش یک بخش به عنوان داده ارزیابی و چهار بخش باقی مانده را به عنوان داده آموزشی در نظر می‌گیریم. به ازای هر vocab size پنج بار آزمایش را تکرار می‌کنیم. که در هر مرحله یک بخش به عنوان داده ارزیابی و چهار بخش باقی مانده را به عنوان داده آموزشی در نظر می‌گیریم. در این بخش tokenize در مرحله word اجرا می‌شود و id توکن unk عدد سه در نظر گرفته شده است. در انتها تعداد توکن‌های unk را به ازای vocab size های مختلف بررسی می‌کنیم. نتایج به دست آمده در شکل۱ قابل مشاهده است. با هر بار اجرا مجدد کد در صورتی که تغییری در نتایج به وجود بیاید شکل۱ به صورت اتوماتیک آپدیت می‌شود.

| | token count | 1 | 2 | 3 | 4 | 5 | average unk token percent |
|---|---|---|---|---|---|---|---|
| **0** | 60 | 42.39 | 42.50 | 42.58 | 42.49 | 42.31 | 42.454 |
| **1** | 500 | 25.67 | 25.47 | 25.49 | 25.16 | 25.40 | 25.438 |
| **2** | 2000 | 11.91 | 11.88 | 11.76 | 11.65 | 11.69 | 11.778 |
| **3** | 5000 | 5.71 | 5.60 | 5.57 | 5.50 | 5.62 | 5.600 |
| **4** | 10067 | 2.54 | 2.47 | 2.46 | 2.36 | 2.36 | 2.438 |

شکل ۱: tokenization result

همچنین نتایج به صورت متن در reports/tokenization.txt و log برنامه در logs/tokenization.log موجود است. برای اجرا آزمایش‌ها و ذخیره مدل نهایی در پوشه مورد نظر کافیست python3 tokenization.py اجرا شود.

همان‌طور که انتظار می‌رفت با افزایش تعداد vocab size تعداد توکن‌های unk به مقدار قابل توجهی کاهش می‌یابد.

## parsing ۳

در این قسمت به کمک کد تمرین ۳ مدل dependency parser را بر روی زبان انگلیسی آموزش داده و تعدادی جمله از دیتاست را انتخاب کرده و parse متناظر با آن‌ها را به صورت دستی نوشته و به عنوان فایل تست، قرار می‌دهیم. فایل تست تولید شده در src/parsing/data/project_data_test.conll قابل مشاهده است (شکل۲).

```
1   1   how _   ADV WRB _   4   aux _   _
2   2   do  _   AUX VBP _   4   nsubj   _   _
3   3   i   _   PRON    PRP _   4   nsubj   _   _
4   4   help    _   VERB    VB  _   0   root    _   _
5   5   my  _   DET VB  _   6   PRP _   _
6   6   mum _   NOUN    NN  _   4   dobj    _   _
7   7   ?   _   PUNCT   .   _   4   punct   _   _
8
```

شکل ۲: correct dependency parser

به عنوان مثال مدل برای جمله موجود در شکل۳ dependency parser را به طور کامل درست تشخیص داده است.

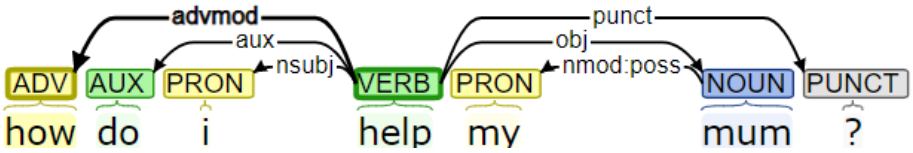


شکل ۳: correct dependency parser

نکته‌ای که در ساخت فایل conll بسیار مهم است و باید بدان توجه شود این است که بین موارد نوشته شده باید یک tab فاصله باشد و در صورت عدم رعایت این فاصله جملات توسط parser به صورت اشتباه خوانده می‌شوند.

## ۴ language model

در این بخش برای آموزش language model ابتدا داده تمیز را به صورت مناسب آماده می‌کنیم. سپس به ازای هر کدام از دسته‌های depresion و happiness داده را به شبکه داده تا مدل زبانی آموزش ببیند. در معماری تعریف شده ایتدا یک لایه embedding قرار داده شده و در ادامه لایه LSTM با 100 hidden state قرار دارد. لایه دیگری bidirectional LSTM و در ادامه یک لایه dense قرار دارد. لایه انتهایی یک لایه dense یا تابع فعال‌سازی softmax می‌باشد که به تعداد همه کلمات موجود نورون دارد. در این لایه به ازای ورودی شبکه مشخص می‌شود چه کلمه باید بعد از عبارت ورودی شبکه بیاید. مدل تعریف شده به صورت شکل۴ می‌باشد. دقت و loss برای کلاس‌های مختلف به صورت شکل۵ و شکل۶ است. با توجه به حذف stopwords و punctuation از جمله و کم‌بودن مشکلاتی در جمله بندی مدل آموزش دیده وجود دارد که در جملات ساخته شده به وضوح مشخص است. عدم وجود I ، am ، are و حروف اضافه‌ای همچون ،is thst در زمان تمیز کردن دیتا باعث شده چنین جملاتی به وجود بیایند.

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
embedding (Embedding)        (None, 10, 50)            499250
_________________________________________________________________
lstm (LSTM)                  (None, 10, 100)           60400
_________________________________________________________________
bidirectional (Bidirectional (None, 200)               160800
_________________________________________________________________
dense (Dense)                (None, 100)               20100
_________________________________________________________________
dense_1 (Dense)              (None, 9985)              1008485
=================================================================
Total params: 1,749,035
Trainable params: 1,749,035
Non-trainable params: 0
```

شکل ۴: شبکه language model

- happiness

take break outside lunch feel like everyone office hate think boring since forced office romantic vacation friend friend whole money laying

- happiness

kill prayed god make accident happen year old relationship family know remember im told reminds friend something really eventually wa using

- happiness

i feel so .. like losing grow shell remember hate suck suck fucked cant

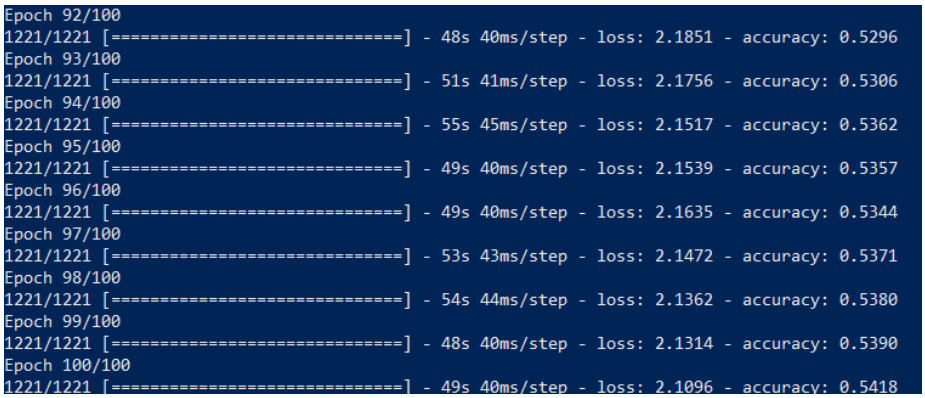


شکل ۵: LSTM accuracy and Loss language model on class depression

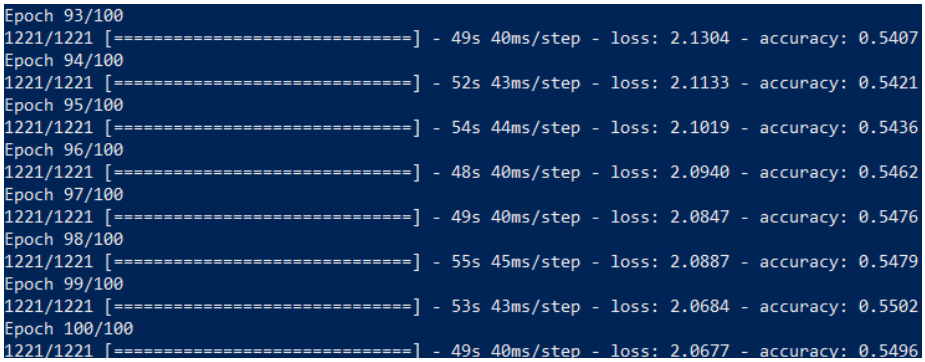


شکل ۶: LSTM accuracy and Loss language model on class happiness

- depression

i feel so .. like edgy movie mind hold supportive defense trash sea man

# finu tuning ۵

## language model ۱.۵

در این بخش با توجه به مطالعات انجام شده بر روی مدل‌های GPT2 در language model و کیفیت خروجی مدل برای این تسک، از distilgpt2 به عنوان مدل pretrain استفاده کرده و مدل را بر دیتاست موجود finetune کردم.

برای اجرا این بخش کافیست python3 fine_tuning.py GPT2 را اجرا کنید. به ازای هر کدام از کلاس‌های depresion و happiness مدل را finetune کرده و وزن‌های حاصله به صورت اتوماتیک در models/depressionGPT2_lm و mosels/happinessGPT2_lm ذخیره می‌شوند. همچنین log در حین اجرا در logs/fine_tuning_GPT2.log قابل مشاهده هست. نمودار تغییرات loss مدل در زمان finetune برای کلاس depression به صورت شکل۷ و برای کلاس happiness به صورت شکل۸ می‌باشد.

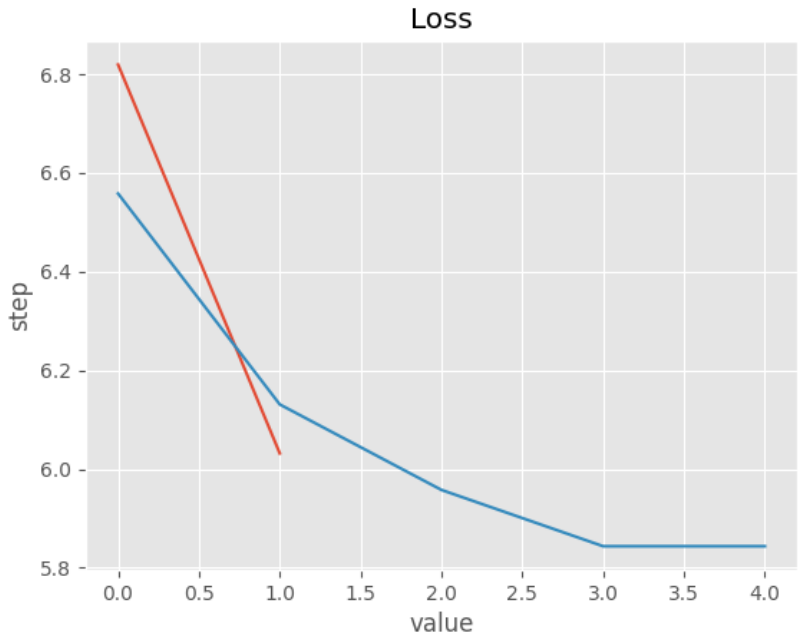


شکل ۷: distilgpt2 Loss language model on class depression


شکل ۸: distilgpt2 Loss language model on class happiness

جملات تولید شده با مدل از قبل آموزش دیده distilgpt2 بسیار با کیفیت‌ترو معنی‌دارتر از جملات تولید شده در قسمت قبل می‌باشد. به ازای هر کدام از کلاس‌ها دو جمله تولید شده که به صورت زیر می‌باشد. نوشته به رنگ آبی توسط مدل تولید شده است.

- happiness

Hi, we have created a success forum for since forced office romantic vacation friend friend whole money laying

- happiness

people interested interested know Hi, we have created a success forum for going want succeed going want fail people want know go past time never successful people want know go past time know succeeding people want know go past time life lived time lived past moment

- happiness

I'm so depressed. I have nothing to live remember im told reminds friend something really eventually wa using

- depression

like edgy movie mind hold sup- I'm so depressed. I have nothing to live portive defense trash sea man

## ۲.۵ classification

در بخش دوم مدل bert-base-uncased از قبل آموزش دیده را برای classification داده‌ها بر روی داده‌های موجود finetune می‌کنیم. برای اجرا این بخش کافیست python3 fine_tuning.py Bert را اجرا کرد. وزن‌های مدل finetune شده در models/bert_classification_lm ذخیره می‌شوند. همچنین log در حین اجرا در logs/fine_tuning_Bert.log می‌باشد. نمودار تغییرات loss در شکل۹ قابل مشاهده است.


شکل ۹: bert-base-uncased Loss classification

# ۶ منابع

https://radimrehurek.com/gensim/models/word2vec.html
https://www.philschmid.de/
fine-tune-a-non-english-gpt-2-model-with-huggingface
https://machinelearningmastery.com/
how-to-develop-a-word-level-neural-language-model-in-keras/
https://gmihaila.github.io/tutorial_notebooks/pretrain_
transformers_pytorch/